
Value-at-Risk sur les indices boursiers MENA

Comparaison de 7 modèles — Backtesting & calibration réglementaire
ARIMA · SARIMA · GARCH · Random Forest · XGBoost · ANN · LSTM

Script de soutenance orale
Guide de présentation du notebook, partie par partie
Durée indicative : 15–20 minutes

Hypothèse testée : le LSTM surpasse les autres modèles sur l'indice ADI (Abu Dhabi). Indices MENA backtestés : Tunindex, ADI, MASI (Maroc), TASI (Arabie Saoudite). CAC 40 et S&P 500 servent de repères de volatilité.

0 Introduction

Durée : 1–2 min

« Ce projet compare 7 modèles — ARIMA, SARIMA, GARCH, Random Forest, XGBoost, ANN et LSTM — pour calculer et backtester la Value-at-Risk sur 4 indices boursiers de la région MENA : Tunindex, ADI (Abu Dhabi), MASI (Maroc) et TASI (Arabie Saoudite). Le CAC 40 et le S&P 500 servent uniquement de repères de contexte pour comparer les niveaux de volatilité — ils ne sont pas backtestés faute de fichier de test dédié. »

« L'hypothèse de départ : le LSTM surpasse les autres modèles sur l'indice ADI. J'ai choisi ADI car son profil — marché relativement liquide mais toujours émergent — semblait a priori favorable à un modèle non-linéaire capable d'apprendre des dépendances temporelles complexes. Je préviens : la conclusion du chapitre 10 ne confirme pas cette hypothèse, et j'assume ce résultat — c'est une conclusion scientifique valable, pas un échec. »

Point méthodologique à annoncer d'emblée

« Chaque modèle est entraîné **une seule fois** sur le train. Ensuite, j'avance jour par jour sur le test : le modèle prédit, puis je réinjecte le rendement réellement observé dans sa fenêtre d'entrée pour la prédiction suivante — mais je ne réestime jamais ses paramètres. C'est le **walk-forward sans réentraînement**, un compromis réaliste entre un modèle figé (trop optimiste) et un modèle réentraîné à chaque pas (irréaliste en production). »

1 Chargement et prétraitement des données

Durée : 2 min

« Les CSV bruts contiennent des dates textuelles, des séparateurs de milliers, des volumes suffixés M/K et des pourcentages — tout est nettoyé par des fonctions de parsing dédiées (`_num`, `_vol`, `load_index`). Je travaille ensuite avec le **rendement logarithmique** : $r_t = 100 \times \ln(P_t / P_{t-1})$. »

Pourquoi le log-retour (3 arguments) :

- **Stationnarité** — le prix a une tendance, le rendement log oscille autour d'une moyenne quasi nulle.
- **Additivité temporelle** — la somme des rendements log sur plusieurs jours égale le rendement cumulé.
- **Symétrie** — le log traite symétriquement une hausse et une baisse de même ampleur.

Chiffres clés (statistiques descriptives)

Indice	Écart-type	Kurtosis	Skew	Remarque
TASI	1.6852 %	élevée	-0.90	Le plus volatil
ADI	1.2701 %	> 3	—	Comparable aux benchmarks
CAC 40 (repère)	1.4468 %	> 3	—	Benchmark développé
S&P 500 (repère)	1.2974 %	14.1	—	Kurtosis la plus forte
MASI	—	4.89	—	Kurtosis la plus faible

Tunindex	—	> 3	-0.54	Skew négatif
----------	---	-----	-------	--------------

Toutes les séries ont une kurtosis > 3 (queues épaisses) et un skew majoritairement négatif : « c'est ce fait stylisé qui justifiera le choix du bootstrap plutôt qu'une hypothèse de normalité. »

2 Analyse exploratoire et décomposition

Durée : 1–2 min

« Sur ADI, je décompose la série en tendance / saisonnalité / résidu avec `seasonal_decompose, period=5` (semaine de 5 jours ouvrés). Un indice n'a pas de vraie saisonnalité physique — c'est un outil pédagogique. Le point important : le graphique de **volatilité glissante** (écart-type sur 20 jours) montre des périodes de forte variance groupées — un **clustering de volatilité**. »

Phrase clé (argument central) :

« C'est précisément ce qu'un modèle à variance constante comme ARIMA ne peut pas capturer, et ce que GARCH est conçu pour modéliser : la variance d'aujourd'hui dépend de la variance et des chocs d'hier. »

3 Stationnarité : tests ADF et KPSS

Durée : 2 min

« Deux tests aux hypothèses nulles opposées, pour une conclusion robuste : **ADF** (H_0 = racine unitaire / non-stationnaire — $p < 0.05 \Rightarrow$ stationnaire) ; **KPSS** (H_0 = stationnaire — $p > 0.05 \Rightarrow$ stationnaire). »

Série (ADI)	ADF p-value	KPSS p-value	Conclusion
Prix	0.4655	0.01	Non-stationnaire (marché aléatoire)
Rendements	0.0000	0.10	Stationnaire (les deux tests concordent)

« C'est la série de rendements — déjà différenciée une fois via le log — qui est utilisée pour tous les modèles, jamais le prix brut. »

ACF/PACF : pas d'autocorrélation linéaire forte sur la moyenne des rendements (marché proche de l'efficience). Mais la **volatilité**, elle, reste fortement autocorrélée — d'où le besoin du GARCH.

4 ARIMA et SARIMA

Durée : 2 min

« Une structure commune `ForecastResult` (`mu`, `sigma`, résidus standardisés) est remplie par tous les modèles, pour appliquer ensuite exactement le même code de VaR et de backtesting. L'ordre (p, d, q) d'ARIMA est trouvé par `auto_arima` (minimisation de l'AIC). SARIMA ajoute une composante saisonnière hebdomadaire $(1, 0, 1)(1, 0, 1, 5)$. Le walk-forward utilise `res.append(refit=False)`. »

Résultats (ADI) : ARIMA MAE = 0.7088 ; SARIMA MAE = 0.7073 — quasiment identiques. La saisonnalité n'apporte quasi rien. **Point clé** : ces deux modèles utilisent un sigma constant — ils ne capturent pas le clustering de volatilité. C'est ce que corrige GARCH.

5 GARCH

Durée : 2–3 min

« **GARCH(1,1)** modélise la variance conditionnelle : $\sigma_t^2 = \omega + \alpha \cdot \varepsilon_{t-1}^2 + \beta \cdot \sigma_{t-1}^2$. ω = niveau de base, α = réaction au choc récent, β = persistance de la volatilité. Quand $\alpha + \beta \rightarrow 1$, les chocs sont très persistants. Les paramètres sont figés après entraînement, mais **sigma est recalculé chaque jour** à partir du choc réalisé la veille — c'est la **Simulation Historique Filtrée (FHS)**. »

Résultats (ADI) : GARCH MAE = 0.6822 (légèrement mieux qu'ARIMA), sigma moyen = 0.9712 %. L'apport réel n'est pas dans le MAE mais dans le sigma qui varie : la bande de VaR « respire » avec le marché.

Diagnostic des résidus (5 tests)

Test	p-value (ADI)	Conclusion
Ljung-Box (résidus ARIMA)	0.943	Moyenne bien captée
ARCH-LM (résidus ARIMA)	< 0.001	Effet ARCH présent → justifie GARCH

ARCH-LM (résidus std. GARCH)	0.862	Hétéroscédasticité absorbée
Jarque-Bera (std. GARCH)	< 0.001	Non-normalité → justifie le bootstrap
Kolmogorov-Smirnov (std. GARCH)	< 0.001	Non-normalité → justifie le bootstrap

Chaîne logique du projet : moyenne bien captée par ARIMA → effet ARCH massif → passage au GARCH → GARCH absorbe l'effet → résidus toujours non-normaux → VaR par bootstrap plutôt que gaussienne.

6 Machine Learning : Random Forest et XGBoost

Durée : 2 min

« RF et XGBoost sont des modèles supervisés génériques : je construis un tableau de features à partir des 5 derniers rendements (lags) pour prédire le rendement suivant. Random Forest agrège 300 arbres sur sous-échantillons aléatoires ; XGBoost construit 300 arbres séquentiellement (learning rate 0.05, profondeur 4) pour contrôler la complexité. »

Résultats (ADI) : RF MAE = 0.6945 (sigma = 0.4731) ; XGBoost MAE = 0.6656 (sigma = 0.8125).

Piège pédagogique à souligner :

« Ces bons scores sont trompeurs. Random Forest a un sigma anormalement faible (0.47 contre ~1.0) — prévisions trop mean-reverting, donc bande de VaR trop étroite. On verra au chapitre 9 un sur-violement massif au backtesting, malgré un MAE correct. »

7 Deep Learning : ANN et LSTM

Durée : 2 min

« L'ANN traite un vecteur fixe de 10 rendements passés à travers 3 couches (10→32→16→1), sans notion d'ordre temporel. Le LSTM traite les rendements un par un dans l'ordre, avec une mémoire interne (32 unités cachées) mise à jour via des portes. Rendements standardisés en entrée, dé-standardisés en sortie. Entraînement sur 20 époques (vs 30 dans le run de référence), compromis pour un temps raisonnable. »

Résultats (ADI) : ANN MAE = 0.6774 ; LSTM MAE = 0.6809 — très proches l'un de l'autre et des modèles classiques. Premier indice : rien ne suggère de supériorité franche du LSTM. Le vrai critère de décision est le backtesting de la VaR, pas le MAE.

8 VaR par Bootstrap Historical Simulation

Durée : 1–2 min

« Formule unifiée : $VaR_t(\alpha) = \mu_t + \sigma_t \times Q_\alpha(\text{bootstrap}(\text{résidus standardisés}))$. Je tire 10 000 résidus avec remise dans le pool du train, et je prends le quantile empirique α . VaR sans aucune loi théorique — la forme empirique des résidus, queues épaisses comprises, est directement utilisée. Une violation = un jour où le rendement réel passe sous la VaR prédite. »

Exemple (LSTM à 95 % sur ADI) : 3 violations sur 170 jours (taux observé 1.76 % contre 5 % attendu) — modèle plutôt conservateur.

9 Backtesting : Kupiec, Christoffersen, zones de Bâle

Durée : 2–3 min

« **Kupiec** vérifie si le nombre total de violations est cohérent avec α (rapport de vraisemblance, Khi-2 à 1 ddl). **Christoffersen** ajoute un test d'indépendance : les violations doivent être dispersées, pas groupées. Les **zones de Bâle** classent les violations normalisées sur 250 jours : verte (conforme), jaune (alerte), rouge (modèle remis en cause). »

Résultat clé	Détail
À 99 % : quasi tous en zone verte	ARIMA, SARIMA, GARCH, XGB, ANN, LSTM — p-Kupiec 0.56 à 0.82
Random Forest problématique (95 %)	Taux observé 21.76 % (vs 5 %), p-Kupiec $\approx 1.3e-13$ → ZONE ROUGE
Random Forest (99 %)	3.53 % observé, p = 0.0099 → zone jaune

« Un bon MAE ponctuel ne garantit absolument pas une VaR bien calibrée. »

1 Comparaison globale et conclusion

Durée : 3–4 min — partie la plus importante

« Pipeline complet : 7 modèles × 4 indices MENA × 2 seuils α = 56 lignes de résultats. C'est le calcul le plus long du notebook. »

Meilleur modèle par indice (à 99 %, trié par p-Kupiec décroissante)

Indice	Meilleur modèle	Taux observé	p-Kupiec	Zone Bâle
ADI	GARCH	1.18 %	0.8220	verte
MASI	GARCH	0.63 %	0.6138	verte
TASI	ARIMA	0.60 %	0.5734	verte
Tunindex	GARCH	1.26 %	0.7534	verte

« **GARCH gagne sur 3 des 4 indices MENA** — son avantage : une variance qui s'adapte jour après jour au clustering de volatilité réel. Sur TASI, ARIMA l'emporte de justesse. Random Forest affiche systématiquement les taux les plus élevés (3.53 % à 6.29 %, soit 3.5 à 6× le taux attendu) sur les 4 indices. »

VERDICT DE L'HYPOTHÈSE

L'hypothèse de départ était : le LSTM surpasse les autres modèles sur ADI. Le meilleur modèle sur ADI est **GARCH** ($p = 0.8220$), pas le LSTM. Le LSTM est bien calibré (zone verte aux deux seuils) mais pas distinctement supérieur : GARCH, ARIMA, SARIMA, XGB et ANN atteignent une calibration du même ordre, voire meilleure.

L'hypothèse n'est donc pas confirmée par ce run, et je l'assume : ce n'est pas un échec du projet, c'est un résultat empirique légitime.

Pourquoi le deep learning ne domine pas ici

- **Échantillons MENA modestes** (quelques centaines à ~2500 observations) — peu pour qu'un LSTM exploite pleinement sa capacité.
- **Dynamique de volatilité fortement structurée** (clustering, autocorrélation de la variance) — exactement ce que GARCH modélise de façon parcimonieuse avec seulement 3 paramètres.

Piste : sur des échantillons plus longs ou à haute fréquence (intra-journalier), l'avantage du deep learning pourrait être différent.

Message de clôture

« La performance de prévision ponctuelle (MAE/RMSE) et la qualité de calibration de la VaR (Kupiec/Christoffersen) sont deux choses différentes. Random Forest le montre : MAE correct, VaR très mal calibrée. Pour un usage réglementaire de type Bâle, c'est la calibration de la **queue de distribution** qui prime sur la précision du point médian — ce qui favorise structurellement les modèles qui modélisent explicitement la variance dans le temps, GARCH, sur les indices MENA étudiés. »

Q Foire aux questions probables du jury

Question	Réponse courte
Pourquoi le rendement log plutôt que le prix ?	Stationnarité, additivité temporelle, symétrie hausse/baisse.
Pourquoi un bootstrap et pas une VaR normale ?	Kurtosis élevée (queues épaisses), confirmée par Jarque-Bera et KS, $p < 0.001$.
Qu'est-ce que le walk-forward « train-once » ?	Un seul entraînement, puis avance jour par jour sans réestimation.
Pourquoi RF est mauvais malgré un bon MAE ?	Sigma trop faible (mean-reverting) → bande de VaR trop étroite → sur-violation.
Pourquoi le LSTM n'a pas gagné ?	Échantillon trop petit ; GARCH spécialisé et parcimonieux (3 paramètres).
Différence Kupiec / Christoffersen ?	Kupiec = nombre total de violations ; Christoffersen ajoute l'indépendance temporelle.
Que représentent les zones de Bâle ?	Classification réglementaire des violations sur 250 jours : verte / jaune / rouge.
Comment améliorer le projet ?	Plus d'époques (30), données intra-journalières, hybride GARCH-LSTM.

T Minutage suggéré (soutenance 15–20 min)

Séquence	Durée
1. Introduction + hypothèse	2 min
2. Données + stationnarité	3 min
3. ARIMA / SARIMA / GARCH	4 min
4. RF / XGBoost / ANN / LSTM	3 min
5. VaR + backtesting (ADI en exemple)	3 min
6. Comparaison globale + verdict + conclusion	4 min
7. Marge questions	reste du temps